UNIVERSIDADE FEDERAL DE ALAGOAS (UFAL) • INSTITUTO DE COMPUTAÇÃO

SISB110 — Ciência dos Dados e Inteligência Empresarial • Bacharelado em Sistemas de Informação

RELATÓRIO EXECUTIVO DE BUSINESS INTELLIGENCE: DETERMINANTES ASSOCIADOS À SAÚDE MENTAL ESTUDANTIL

Evidências Descritivas, Inferenciais e Diretrizes de Ação para a Gestão Universitária

Estudante: Bruno Martins Gomes • Docente / Disciplina: SISB110 / UFAL • Outubro / 2026

RESUMO EXECUTIVO (EXECUTIVE SUMMARY)

Contexto e Problema de Negócio: A persistência do adoecimento psíquico e o risco de evasão na educação superior impõem à gestão universitária a necessidade de decisões alocativas baseadas em evidências empíricas. Este estudo analisa uma amostra transversal de **27.837 estudantes universitários** (derivada da versão integral de 27.901 registros do *Student Depression Dataset*, Kaggle/Hopesb) sob a ótica de Business Intelligence (BI) para apoio psicopedagógico e permanência estudantil.

Principais Achados Empíricos:

• **Prevalência Amostral Estimada:** A proporção de estudantes com indicativo de depressão na população amostrada é de **58,52%** (IC 95% de Wilson: **[57,94%, 59,10%]**, margem de erro de ±0,58%).

• **Vulnerabilidade Financeira como Maior Preditador Associativo:** O estresse financeiro exibe associação moderada (Cramér's $V = 0,36$) e **forte tendência linear monotônica** (Cochran-Armitage $Z = 60,67$, $p < 0,0001$), com a taxa de depressão saltando de **31,81%** no nível 1 para **81,23%** no nível 5 (acréscimo de ~50 pontos percentuais).

• **Sobrecarga Acadêmica:** Estudantes com indicativo de depressão reportam pressão percebida substancialmente superior (3,69 vs. 2,36; Mann-Whitney $U = 1,45 \times 10^8$, $p < 0,0001$; d de Cohen = 1,10). A correlação bisserial por postos ($r_{rb} = 0,5408$) reflete uma **probabilidade de superioridade de aproximadamente 77%, contando empates pela metade**.

• **Sono e Risco nos Extremos:** A privação severa (< 5h/dia) registra a maior taxa (**64,51%**), enquanto sono prolongado (> 8h) apresenta a menor (**50,86%**), com associação global fraca ($V = 0,10$) e não-monotônica (faixa 5–6h = 56,85% vs. 7–8h = 59,45%).

• **Desconexão entre Notas e Satisfação:** O rendimento acadêmico (CGPA) não possui correlação prática substantiva com a satisfação com os estudos (Spearman $\rho = -0,0467$; $p < 0,0001$, $|\rho| < 0,10$).

Principal Recomendação Institucional: Recomenda-se direcionamento orçamentário prioritário de auxílios e bolsas de permanência discente aos estudantes em vulnerabilidade financeira crítica (níveis 4 e 5), associado a diretrizes pedagógicas de escalonamento avaliativo para diluição dos picos de pressão curricular. Ações de suporte psicossocial não devem adotar o desempenho acadêmico (CGPA) como critério de elegibilidade ou triagem.

2. Introdução e Contexto de Negócio

A evasão no ensino superior e o sofrimento psíquico discente constituem desafios estratégicos de primeira ordem para a administração universitária. Sob o paradigma de **Business Intelligence (BI) e Inteligência Empresarial aplicada à Gestão Educacional**, a instituição atua como decisora central na alocação de recursos públicos e humanos limitados (bolsas de assistência estudantil, serviços de acolhimento psicossocial e organização de calendários acadêmicos). Identificar padrões empíricos associados ao adoecimento mental discente permite transformar dados brutos em decisões informadas e intervenções preventivas estruturadas.

Origem e Rastreabilidade da Base: Os dados decorrem do *Student Depression Dataset*, originalmente disponibilizado no Kaggle por Shodolamu Opeyemi (hopesb/student-depression-dataset, 27.901 linhas e 18 colunas), sob licença aberta **Apache 2.0**. Utilizou-se o espelho integral hospedado no Hugging Face Datasets (urmah/student-depression-analysis). Confirmou-se tratar-se da versão volumosa integral, afastando homônimos reduzidos (~500 linhas).

Objetivo Geral e Perguntas Decisórias (P1 a P5): Avaliar a prevalência e a força de associação entre determinantes acadêmicos, comportamentais e socioeconômicos e o indicativo de depressão autorrelatada, subsidiando a Pró-Reitoria de Assistência Estudantil:

#	Pergunta de Negócio (BI)	Variáveis Envolvidas	Decisão Organizacional / Impacto
P1	Qual a proporção estimada de estudantes com indicativo de depressão na população amostrada?	Depression (0/1)	Dimensionamento de capacidade e planejamento do núcleo psicossocial.
P2	A sobrecarga curricular percebida difere entre quem tem e quem não tem indicativo de depressão?	Academic Pressure (0–5) × Depression	Ajuste pedagógico de matriz curricular e modulação de avaliações.
P3	A duração habitual do sono está associada à ocorrência de indicativo de depressão?	Sleep Duration (4 faixas) × Depression	Campanhas preventivas de higiene do sono e ajuste de horários.
P4	A prevalência de depressão varia e exibe tendência linear crescente com o estresse financeiro?	Financial Stress (1–5) × Depression	Focalização prioritária de auxílios e bolsas de permanência discente.
P5	Existe correlação substantiva entre satisfação com os estudos e rendimento acadêmico (CGPA)?	Study Satisfaction (0–5) × CGPA (0–10)	Desvincular o acolhimento institucional de critérios de notas altas.

3. Metodologia e Tratamento dos Dados

Ambiente Computacional e Reprodutibilidade: O pipeline foi construído em Python 3.14 (pacotes pandas, numpy, scipy, statsmodels, matplotlib, seaborn e reportlab), consolidado no notebook analise_depressao.ipynb sob semente aleatória fixa (42). Todos os caminhos de dados e saídas são estritamente relativos (data/ e outputs/).

Auditoria e Higienização dos Dados (Contabilidade Rigorosa): A base original possuía 27.901 linhas e 18 colunas. O protocolo reprodutível de higienização compreendeu:

- **Valores Ausentes:** Apenas 3 registros em Financial Stress possuíam valores nulos (IDs 22377, 68910 e 97610; 0,01% da base), excluídos por análise de casos completos sem afetar o equilíbrio amostral.
- **Filtragem de Escopo Discente:** 31 registros (0,11%) possuíam ocupações não-estudantis (ex.: *Civil Engineer, Architect*), sendo excluídos para assegurar estrita representatividade estudantil.
- **Categorias Espúrias 'Others':** Excluíram-se 18 ocorrências em Sleep Duration e 12 em Dietary Habits (30 casos, 0,11%) por ausência de significado discriminatório.
- **Descarte de Colunas Constantes:** As colunas Work Pressure e Job Satisfaction continham 99,99% e 99,97% de valores zerados (por ausência de vínculo empregatício discente formal), sendo descartadas.
- **Tratamento dos Zeros de CGPA e Sensibilidade:** Identificaram-se 9 estudantes com CGPA = 0,0 (0,03%), enquanto o percentil 1% é 5,11. Esses registros foram classificados como notas não lançadas/inválidas e removidos das análises de rendimento. A análise de sensibilidade comprovou que a mediana do CGPA permanece estritamente em **7,77** (IQR = 2,63) com ou sem esses registros, e a média varia apenas 0,003 ponto (7,656 vs. 7,659).
- **Tratamento Padronizado dos Zeros em Escalas Likert:** Identificaram-se 9 zeros em Academic Pressure (0,03%) e 10 zeros em Study Satisfaction (0,04%). Como essas escalas adotam domínio de 1 a 5 (conforme padronizado em Financial Stress), esses zeros refletem código de não-resposta. Pela análise de sensibilidade, mantê-los na base altera a média em menos de 0,0011 ponto e mantém a mediana idêntica em 3,0.
- **Suposições da Amostra (Idades e Horas):** A coluna Work/Study Hours possui 1.700 casos com valor 0 (6,09%), o que se cogita decorrer de períodos de férias ou trancamento de matrícula; *trata-se de uma possível explicação, não verificável com esta base de dados*. Da mesma forma, 12 casos (0,04%) de idade entre 44 e 59 anos foram mantidos como outliers naturais válidos sob a suposição de alunos de pós-graduação ou ingresso tardio; *trata-se, igualmente, de uma possível explicação, não verificável com esta base de dados*.

Volume Amostral Final Tratado: 27.837 estudantes universitários (apenas 64 linhas descartadas no total, correspondendo a meros **0,23%** do volume original).

Pressupostos e Rigor Metodológico: Em grandes volumes amostrais ($N > 27.000$), testes de hipóteses de normalidade (Shapiro-Wilk) tornam-se hiper-sensíveis a desvios mínimos. A verificação de pressupostos foi conduzida por **inspeção visual de gráficos Q-Q e histogramas** (outputs/06_pressupostos_normais.png), confirmando o comportamento em patamares discretos das escalas ordinais e embasando a priorização de métodos não-paramétricos (Mann-Whitney U e correlação de Spearman).

4. Análise Descritiva e Exploratória dos Dados

A análise univariada e bivariada sintetiza o perfil sociodemográfico, comportamental e acadêmico dos 27.837 discentes avaliados.

Tabela 1: Estatísticas Descritivas das Variáveis Numéricas e Escalas (N = 27.837)

Variável	Média	Desv. Padrão	Mediana	IQR	Mín.	Máx.	Assimetria	Curtose
Age (Idade)	25,82	4,91	25,00	9,00	18,0	59,0	+0,13	-0,85
CGPA (s/ zeros)	7,66	1,46	7,77	2,63	5,03	10,0	-0,07	-1,23
Academic Pressure (0–5)	3,14	1,38	3,00	2,00	0,0	5,0	-0,13	-1,16
Study Satisfaction (0–5)	2,94	1,36	3,00	2,00	0,0	5,0	+0,01	-1,22
Work/Study Hours	7,16	3,71	8,00	6,00	0,0	12,0	-0,46	-1,00
Financial Stress (1–5)	3,14	1,44	3,00	2,00	1,0	5,0	-0,13	-1,32

Tabela 2: Distribuição de Frequências das Variáveis Categóricas (N = 27.837)

Variável	Categorias e Níveis	Freq. Absoluta (N)	Freq. Relativa (%)
Depression (Desfecho)	1 (Com indicativo) / 0 (Sem indicativo)	16.290 / 11.547	**58,52%** / 41,48%
Gender (Gênero)	Masculino ('Male') / Feminino ('Female')	15.511 / 12.326	55,72% / 44,28%
Sleep Duration (Sono)	< 5h / 7–8h / 5–6h / > 8h	8.297 / 7.334 / 6.172 / 6.034	29,81% / 26,35% / 22,17% / 21,68%
Dietary Habits (Dieta)	Unhealthy / Moderate / Healthy	10.300 / 9.903 / 7.634	37,00% / 35,57% / 27,42%
Suicidal Thoughts	Sim ('Yes') / Não ('No')	17.610 / 10.227	**63,26%** / 36,74%
Family History	Não ('No') / Sim ('Yes')	14.364 / 13.473	51,60% / 48,40%

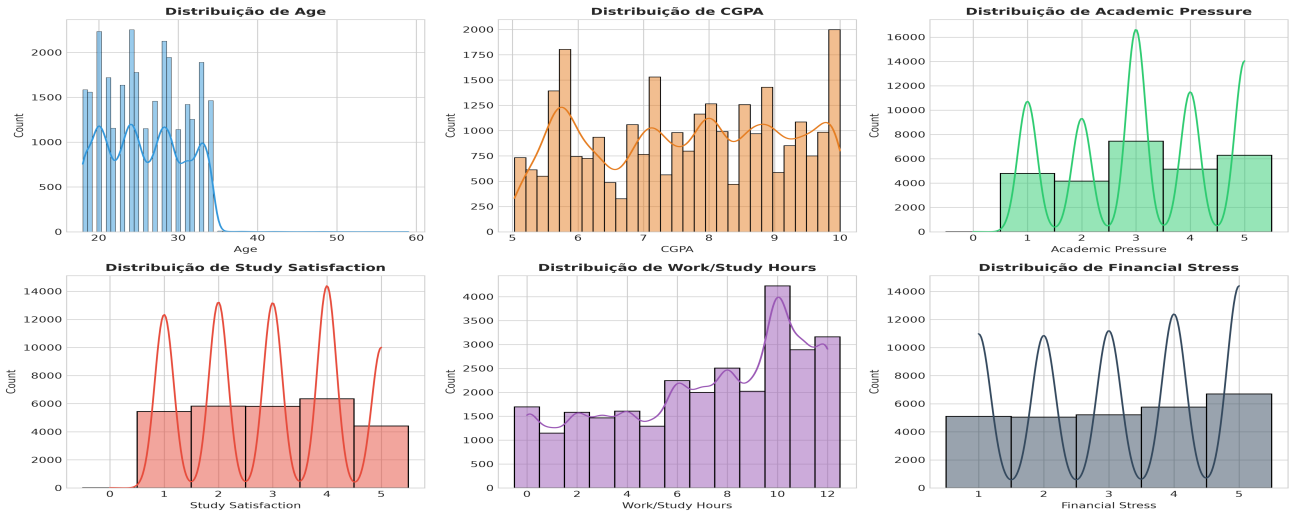


Figura 1: *Distribuições empíricas e curvas KDE das 6 variáveis numéricas e escalas discentes.*

Comportamento Bivariado: Sono e Estresse Financeiro vs. Depressão

A Tabela 3 detalha a taxa de depressão estratificada pelas faixas de sono (P3) e pelos níveis de estresse financeiro (P4). Nota-se que o estresse financeiro exibe um gradiente monotônico estrito, enquanto o sono revela maior prevalência nos extremos de privação severa (< 5 horas).

Duração do Sono	Taxa Depressão (%)	Nível Estresse Financeiro	Taxa Depressão (%)
< 5 hours (Privação severa)	**64,51% (5.352 / 8.297)**	Nível 1 (Mínimo estresse)	**31,81% (1.625 / 5.108)**
5–6 hours (Sono curto)	**56,85% (3.509 / 6.172)**	Nível 2 (Baixo estresse)	**42,94% (2.170 / 5.053)**
7–8 hours (Sono padrão)	**59,45% (4.360 / 7.334)**	Nível 3 (Estresse moderado)	**58,91% (3.071 / 5.213)**
> 8 hours (Sono prolongado)	**50,86% (3.069 / 6.034)**	Nível 4 (Alto estresse)	**69,09% (3.983 / 5.765)**
Média Global da Amostra	**58,52% (16.290 / 27.837)**	Nível 5 (Máximo estresse)	**81,23% (5.441 / 6.698)**

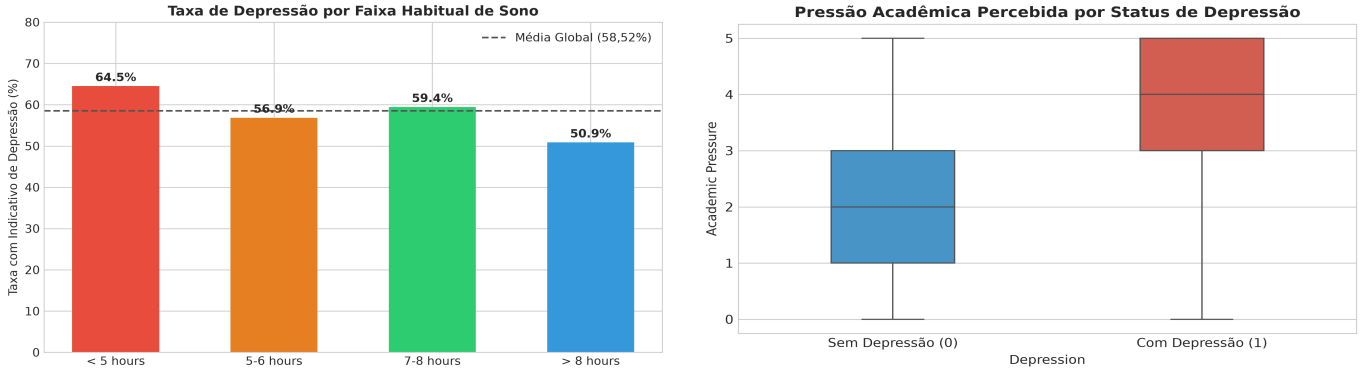


Figura 2: *Proporção de depressão por faixa de sono (esquerda) e distribuição da pressão acadêmica por status de depressão (direita).*

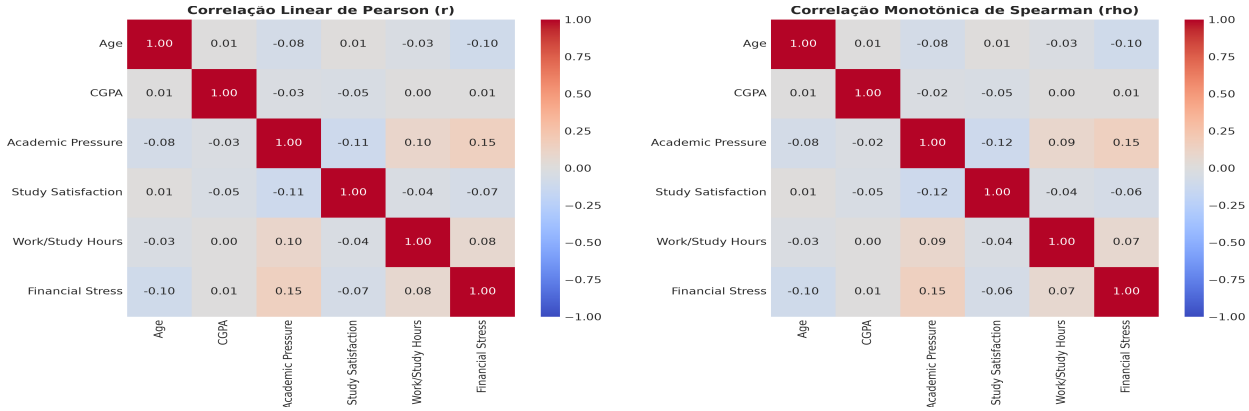


Figura 3: *Mapas de calor das matrizes de correlação linear de Pearson (esquerda) e monotônica de Spearman (direita).*

5. Análise Inferencial e Validação de Hipóteses

Declarou-se o nível de significância prévio α = 0,05. Cada teste foi vinculado às hipóteses formais de pesquisa (H_0 e H_1), acompanhado de sua estatística, graus de liberdade, p-valor e **tamanho de efeito padronizado**.

#	Hipóteses Formais (H_0 e H_1)	Procedimento	Estatística & p-valor	Tamanho de Efeito	Decisão (α = 0,05)
P 1	Estimar proporção populacional (p) de depressão na população amostrada.	IC 95% de Wilson score	k = 16.290, N = 27.837 $\hat{p}$ = **58,52%**	**Margem: ±0,58% [57,94%, 59,10%]**	Estimativa precisa para a população da pesquisa.
P 2	**H_0:** $F_{com}(x) = F_{sem}(x)$ **H_1:** $F_{com}(x) \neq F_{sem}(x)$	**Mann-Whitney U** (Principal) + Welch t (Confirmatório)	$U = 1{,}45 \times 10^8$, $p <$ 0,0001 t = 89,21, $p <$ 0,0001	**r_{rb} = 0,5408** **Prob. Superioridade: ≈ 77% (empates/2)** ***d* de Cohen = 1,0950**	**Rejeita H_0. Associação de grande magnitude.**
P 3	**H_0:** Duração do sono e depressão são independentes. **H_1:** Sono e depressão estão associados.	Qui-Quadrado de Independência (χ^2)	χ^2 = 277,90, gl = 3 $p = 6{,}03 \times 10^{-60}$	Cramér's V = **0,0999 (~0,10)** (Efeito Fraco, não-monotônico)	**Rejeita H_0.** Relevância prática modesta.
P 4	**H_0:** Independência e sem tendência. **H_1:** Tendência monotônica crescente de depressão com estresse financeiro.	Qui-Quadrado (χ^2) + Tendência de **Cochran-Armitage**	χ^2 = 3.695,04, gl = 4, $p <$ 0,0001 Z = **60,67**, $p <$ 0,0001	**Cramér's *V* = 0,3643 (Moderado)** **Tendência monotônica Forte (31,8% a 81,2%)**	**Rejeita H_0. Forte gradiente socioeconômico.**
P 5	**H_0:** Correlação nula (ρ = 0). **H_1:** Correlação diferente de zero (ρ ≠ 0).	Correlação Monotônica de **Spearman (ρ)** + Pearson (r)	N = 27.828 $p = 6{,}85 \times 10^{-15}$	**Spearman *ρ* = -0,0467** **Pearson *r* = -0,0466**	**Rejeita H_0 matemático (poder do *N*), mas EFEITO PRÁTICO DESPREZÍVEL (|ρ| < 0,10).**

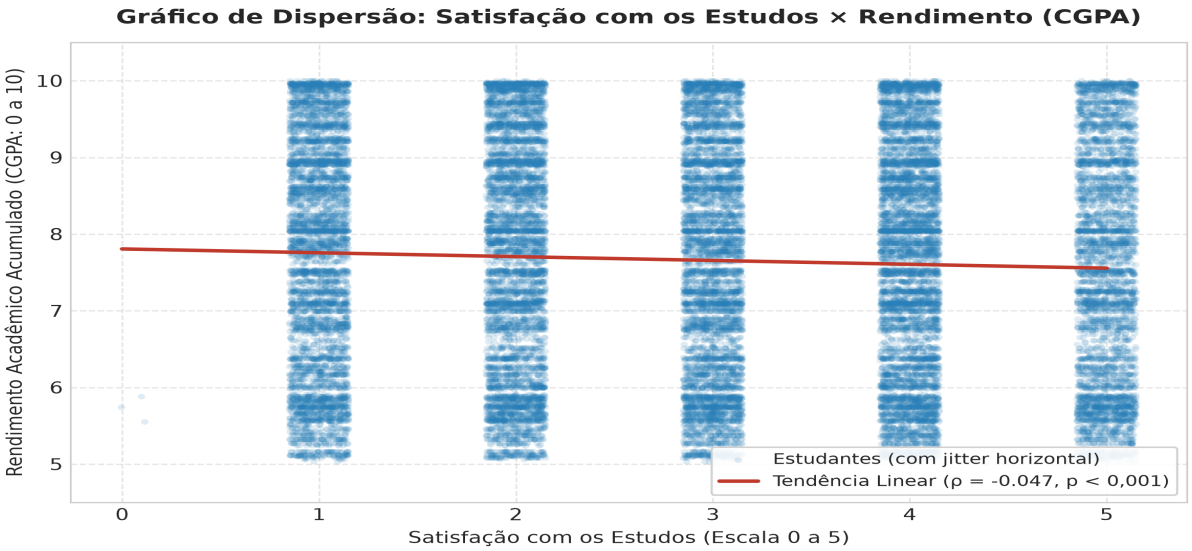


Figura 4: *Gráfico de dispersão entre Satisfação com os Estudos (0–5) e Rendimento Acadêmico Acumulado (CGPA: 0–10), com jitter horizontal (±0,15), transparência de densidade, reta de tendência linear e indicação do coeficiente de correlação de postos de Spearman (ρ = -0,0467, p < 0,001).*

Interpretação Substantiva dos Efeitos:
1. **Probabilidade de Superioridade (P2):** A correlação bisserial por postos de $r_{rb} = 0{,}5408$ converte-se em uma **probabilidade de superioridade de aproximadamente 77%, contando empates pela metade** ($CLES = (r_{rb} + 1) / 2$). Esse refinamento conceitual é metodologicamente necessário em virtude da natureza discreta da escala ordinal de pressão acadêmica (0 a 5), na qual há um número substantivo de empates entre pares de estudantes.
2. **Gradiente Financeiro vs. Sono (P4 vs. P3):** O estresse financeiro exibe um V de Cramér de **0,36 (moderado)** associado a uma tendência monotônica **forte** comprovada pelo teste de Cochran-Armitage ($Z = 60{,}67$), saltando de 31,8% no nível 1 para 81,2% no nível 5. Em contrapartida, o sono exibe associação global fraca ($V = 0{,}10$) e comportamento não-monotônico, indicando que a assistência financeira possui impacto associativo preponderante.
3. **Dispersão e Desconexão Prática (P5):** Como ilustrado na **Figura 4**, a dispersão uniforme com jitter horizontal e a inclinação praticamente plana da linha de tendência linear evidenciam que o coeficiente de Spearman ($\rho = -0{,}0467$; $p < 0{,}0001$), embora formalmente significativo pelo tamanho amostral expressivo ($N = 27.828$), possui relevância prática negligenciável ($|\rho| < 0{,}10$).
4. **Controle de Comparações Múltiplas:** O estudo compreende **4 famílias de hipóteses** (a P1 é um intervalo de confiança de estimativa, e a P2 envolve dois testes concorrentes sobre a mesma hipótese). Aplicando a correção sequencial de Holm-Bonferroni sobre as 4 famílias ($p_1, p_2, p_3, p_4 < 10^{-14}$), todas as hipóteses nulas permanecem rejeitadas com folga, assegurando controle estrito da taxa de erro global (FWER ≤ 0,05).

6. Recomendações Práticas e Plano de Ação de BI

Apoiado nas evidências estatísticas, propõe-se um plano de ação para a gestão universitária (Pró-Reitorias de Assistência Estudantil e de Graduação):

Eixo Estratégico	Evidência Empírica Base	Ação Recomendada (Plano Institucional de BI)
1. Permanência e Assistência Material	P4: 81,2% de depressão no nível 5 de estresse financeiro vs. 31,8% no nível 1 (Cochran-Armitage $Z = 60{,}67$).	**Priorização focalizada do PNAES/Bolsas:** Utilizar questionário socioeconômico semestral para identificar ativamente discentes nos níveis 4 e 5 de vulnerabilidade, canalizando bolsas de permanência, moradia e alimentação prioritária antes da ocorrência de evasão.
2. Gestão Curricular e Pedagógica	P2: d de Cohen = 1,10; probabilidade de superioridade de aproximadamente 77%, contando empates pela metade, na pressão acadêmica.	**Escalonamento e Modulação de Avaliações:** Implementar diretrizes pedagógicas para que colegiados de curso evitem concentração excessiva de entregas e provas na mesma semana, criando fóruns de apoio psicopedagógico em disciplinas sobrecarregadas.
3. Higiene do Sono e Rotina	P3: Maior taxa de depressão concentrada na privação extrema (< 5h = 64,51%).	**Oficinas de Manejo de Rotina e Gestão de Turnos:** Promover oficinas de saúde preventiva do sono durante o acolhimento institucional e avaliar flexibilizações de horários para cursos com aulas em turnos extremos.
4. Política de Acolhimento Sem Viés de Nota	P5: Correlação insignificante entre rendimento (CGPA) e satisfação ($\rho = -0{,}047$; Figura 4).	**Desvinculação entre Suporte Psicológico e Coeficiente de Rendimento:** O serviço psicopedagógico não deve condicionar nem priorizar atendimentos com base em notas baixas, visto que alunos com CGPA de excelência sofrem igualmente de sobrecarga e sofrimento psíquico.

7. Referências, Apêndices e Limitações Metodológicas

LINK DO REPOSITÓRIO PÚBLICO (GITHUB) & FONTES:

- **Repositório do Projeto:** https://github.com/brunomartinsgg/sisb110-depressao-estudantes
- **Fonte Primária Original:** *Student Depression Dataset* no Kaggle (https://www.kaggle.com/datasets/hopesb/student-depression-dataset, autor Shodolamu Opeyemi, Licença Apache 2.0).
- **Espelho Utilizado:** Hugging Face Datasets (https://huggingface.co/datasets/urmah/student-depression-analysis).

Apêndice Metodológico: Dicionário de Dados e Tipagem das Variáveis

Coluna	Classificação Estatística	Domínio / Unidade	Tratamento e Decisão Metodológica
id	Identificador Técnico	Inteiro único	Mantido para rastreabilidade; 0 duplicatas.
Gender	Categórica Nominal	'Male', 'Female'	Tipada como categoria dicotômica.
Age	**Quantitativa Discreta**	18 a 59 anos inteiros	Mantidos outliers de Tukey (>43,5 anos) sob suposição discente.
City	Categórica Nominal	52 municípios	Mantida para caracterização geográfica.
Profession	Categórica Nominal	'Student' (exclusivo)	Filtrada; 31 registros não-estudantes removidos.
Academic Pressure	Qualitativa Ordinal / Escala	0 a 5 (escala)	9 zeros analisados por sensibilidade e mantidos.
CGPA	Quantitativa Contínua/Razão	0,0 a 10,0	9 zeros tratados como ausentes para análises de CGPA.
Study Satisfaction	Qualitativa Ordinal / Escala	0 a 5 (escala)	10 zeros analisados por sensibilidade e mantidos.
Sleep Duration	Categórica Ordinal	4 faixas de horas	18 registros 'Others' descartados por ruído.
Dietary Habits	Categórica Ordinal	3 níveis qualitativos	12 registros 'Others' descartados por ruído.
Degree	Categórica Nominal	28 títulos acadêmicos	Mantida para contextualização do grau acadêmico.
Suicidal Thoughts	Categórica Nominal / Binária	'Yes', 'No'	Indicador sensível de alerta ético institucional.
Work/Study Hours	**Quantitativa Discreta**	0 a 12 horas inteiras/dia	6,09% com 0h mantidos sob suposição de férias/trancamento.
Financial Stress	Qualitativa Ordinal / Escala	1 a 5 (escala)	3 nulos pontuais excluídos por complete case analysis.
Family History	Categórica Nominal / Binária	'Yes', 'No'	Histórico familiar de saúde mental autorreportado.
Depression	Categórica Nominal / Binária	0 (Não), 1 (Sim)	**Desfecho binário principal de interesse analítico.**

Limitações Metodológicas Obrigatórias e Rigor de Interpretação:

1. **Natureza Observacional e Causalidade Reversa:** Trata-se de um estudo seccional observacional. Toda associação estatística observada não configura relação de causalidade. É altamente plausível a ocorrência de causalidade reversa, na qual discentes que já vivenciam quadros depressivos desenvolvam maior vulnerabilidade financeira subjetiva e percepção amplificada de sobrecarga acadêmica.
2. **Autorrelato vs. Diagnóstico Clínico Estruturado:** A mensuração de depressão baseia-se em questionário autoaplicado de percepção individual, carecendo de confirmação diagnóstica via entrevistas psiquiátricas ou instrumentos clínicos validados baseados nos manuais DSM-5 ou CID-11.
3. **Viés de Resposta e Amostra Não Probabilística:** As taxas registradas na amostra (58,5% de indicativo de depressão e 63,3% de ideação suicida) são substancialmente superiores às médias epidemiológicas globais em populações gerais de universitários, o que evidencia forte viés de autosseleção na adesão à pesquisa. Os resultados aplicam-se estritamente à população discente representada pelos respondentes deste questionário.
4. **Cuidado Ético Humanizado em Saúde Mental:** Os dados relativos a ideação suicida e sofrimento mental exigem tratamento estritamente técnico e confidencial. Devem servir exclusivamente como embasamento para a criação de redes acolhedoras de suporte multiprofissional (psicólogos, assistentes sociais e pedagogos) e nunca para triagens punitivas, vigilância discriminatória ou estigmatização de discentes.